



Politechnika Łódzka

**Wydział Fizyki Technicznej, Informatyki
i Matematyki Stosowanej**

Aneta Malinowska
259279

PRACA DYPLOMOWA
magisterska
na kierunku Informatyka Stosowana

**Automatyzacja personalizowanego planowania zadań
z uwzględnieniem zmęczenia i rytmu dobowego**

Instytut Informatyki I72

Promotor: dr inż. Joanna Ochelska-Mierzejewska

ŁÓDŹ 2026

Spis treści

1	Wstęp	2
1.1	Problematyka i zakres pracy	2
1.2	Cele pracy	2
1.3	Układ pracy	3
2	Przegląd literatury	4
2.1	Automatyzacja i personalizacja planowania zadań	4
2.1.1	Metodyka systematycznego przeglądu literatury	4
2.1.2	Pytania badawcze przeglądu	5
2.1.3	Strategia wyszukiwania	5
2.1.4	Warunki uwzględnienia i wykluczenia	6
2.1.5	Ocena jakości (<i>Quality Assessment</i>)	7
2.1.6	Procedura selekcji	7
2.1.7	Ekstrakcja i synteza danych	9
2.1.8	Wyniki systematycznego przeglądu literatury	9
2.1.9	Opis badań podstawowych	10
2.1.10	Wykaz analizy jakości (<i>Quality Assessment</i>)	10
2.1.11	RQ1: Jakie są obecne podstawy algorytmiczne w personalizowanym planowaniu zadań i jak wybrane metody (GA, RL, agenci AI) wypadają w bezpośrednim porównaniu?	10
2.1.12	RQ2: Jakie parametry i ograniczenia skoncentrowane na użytkowniku (np. zmęczenie, przerwy, rytm okołodobowy) są najczęściej włączane do omawianych modeli?	14
2.1.13	RQ3: W jaki sposób dane o historycznej wydajności użytkownika (np. średni czas realizacji zadań) są wykorzystywane do personalizacji przyszłych przewidywań w harmonogramie?	15
2.1.14	RQ4: Jakie są główne metody weryfikacji, wyzwania oraz ograniczenia zidentyfikowane w aktualnych rozwiązaniach dotyczących planowania zadań?	15
2.1.15	Dyskusja	17
2.2	Rytm dobowy i modelowanie funkcjonowania człowieka	19
2.3	Synteza literatury i luka badawcza	19
3	Wybrane zagadnienia teoretyczne z zakresu automatyzacji planowania zadań i personalizacji	20
3.1	Problem automatycznego planowania zadań	20
3.1.1	Planowanie i harmonogramowanie zadań	20
3.1.2	Problemy Job-Shop Scheduling i Flexible Job-Shop Scheduling	20

3.1.3	Modelowanie zadań, zasobów i ograniczeń	20
3.1.4	Dynamiczne przeplanowanie zadań	20
3.1.5	Personalizacja i podejście Human-in-the-Loop	20
3.2	Optymalizacja wielokryterialna	20
3.2.1	Problem optymalizacji wielokryterialnej	20
3.2.2	Dominacja Pareto i front Pareto	20
3.2.3	Algorytmy ewolucyjne w optymalizacji wielokryterialnej	20
3.2.4	Algorytm NSGA-II	20
3.2.5	Algorytm NSGA-III	20
3.3	Uczenie przez wzmacnianie	20
3.3.1	Podstawy uczenia przez wzmacnianie	20
3.3.2	Proces decyzyjny Markowa	20
3.3.3	Funkcja nagrody i polityka agenta	20
3.3.4	Proximal Policy Optimization	20
3.3.5	Informacja zwrotna użytkownika w procesie uczenia	20
3.4	Modelowanie zmienności funkcjonowania człowieka	20
3.4.1	Rytm okołodobowy	20
3.4.2	Chronotyp i różnice indywidualne	20
3.4.3	Zmęczenie i wydajność podczas wykonywania zadań	20
3.4.4	Odpoczynek i regeneracja	20
3.4.5	Reprezentacja stanu użytkownika w systemie planowania	20
4	Wykorzystane dane i stos technologiczny	21
4.1	Bazy danych	21
4.2	Augmentacja i synteza danych	21
4.3	Wykorzystane technologie	21
5	Konstrukcja eksperymentu porównania metod planowania	22
5.1	Składowe elementy uwzględnione w eksperymencie	22
5.2	Miary oceny	22
5.3	Modelowanie funkcjonowania człowieka	22
5.4	Architektura modeli	23
5.4.1	Punkt odniesienia	23
5.4.2	Niezdominowany Algorytm Sortowania Genetycznego - NSGAPlanner	23
5.4.3	Proximal Policy Optimization - PPOPlanner	23
5.5	Plan eksperymentu	23
6	Wyniki	24
6.1	Etap 1	24
6.2	Etap 2	24

7 Podsumowanie	25
7.1 Analiza wyników eksperymentu	25
7.2 Ocena użyteczności wybranych metod automatyzacji planowania zadań	25
7.3 Możliwość dalszego rozwoju tematyki pracy	25
Spis rysunków	26
Spis tabel	27

Streszczenie

Abstract

Słowa kluczowe: automatyzacja planowanie zadań uczenie przez wzmacnianie algorytm genetyczny produktywność rytm dobowy personalizacja

Keywords: automation task planning reinforcement learning genetic algorithm productivity circadian rhythm personalization

1 Wstęp

1.1 Problematyka i zakres pracy

We współczesnych środowiskach zawodowych oraz akademickich regularnie obserwuje się wzrost oczekiwań dotyczących liczby i złożoności realizowanych zadań. Jednocześnie skuteczne planowanie aktywności człowieka stanowi złożony problem, ponieważ jego wydajność nie jest wartością stałą i może zmieniać się w zależności od czynników wewnętrznych i zewnętrznych. W szczególności znaczenie mają zmęczenie, potrzeba odpoczynku, rytm dobowy oraz indywidualne różnice w sposobie funkcjonowania. Nieuwzględnianie tej zmienności może prowadzić do tworzenia planów niedostosowanych do rzeczywistych możliwości użytkownika, a w konsekwencji do spadku efektywności, narastania obciążenia oraz powielania negatywnych nawyków.

Odpowiedzią na te wyzwania mogą być inteligentne systemy wspomagania decyzji, automatyzujące proces harmonogramowania w sposób spersonalizowany. W przeciwieństwie do klasycznych metod opartych na sztywnych parametrach i wcześniej zdefiniowanych regułach, rozwiązania adaptacyjne mogą uwzględniać zmiany stanu użytkownika, jego historyczną wydajność oraz informacje zwrotne dotyczące realizacji planu. Pozwala to na bieżące dostosowywanie harmonogramu do indywidualnych cech użytkownika oraz zmienności jego funkcjonowania w czasie.

Choć metody automatycznego planowania są szeroko rozwijane w kontekście procesów systemowych, produkcyjnych czy współpracy człowieka z maszyną, ich zastosowanie w codziennym, indywidualnym planowaniu zadań nadal pozostaje ograniczone. Istotnym problemem jest również sposób reprezentowania czynników ludzkich, takich jak zmęczenie i regeneracja. W części istniejących rozwiązań odpoczynek traktowany jest jako aktywny element planu, jednak w wielu przypadkach jego wpływ na stan użytkownika nie jest jawnie modelowany.

Niniejsza praca podejmuje tę tematykę poprzez formalizację wpływu rytmu dobowego, chronotypu, narastającego zmęczenia oraz regeneracji podczas odpoczynku na proces planowania zadań. Zakres pracy obejmuje analizę istniejących metod automatycznego harmonogramowania oraz opracowanie modelu symulacyjnego użytkownika, umożliwiającego prowadzenie eksperymentów porównawczych dla wybranych algorytmów w jednolitych warunkach.

1.2 Cele pracy

Głównym celem pracy jest opracowanie oraz eksperymentalna ocena wybranych metod automatycznego planowania zadań, z ukierunkowaniem na personalizację harmonogramu dla konkretnego użytkownika. W szczególności analizowany jest wpływ rytmu dobowego oraz zmienności funkcjonowania użytkownika w czasie, wynikającej z narastającego zmęczenia i regeneracji zachodzącej podczas odpoczynku. W związku z tym kluczowe jest zapoznanie się z metodami modelowania poziomu energii i wydajności człowieka z uwzględnieniem różnych chronotypów, a także dobór inteligentnych metod harmonogramowania umożliwiających uwzględnienie wielu

zmiennych opisujących zarówno użytkownika, jak i realizowane zadania.

W celu zapewnienia jednolitych warunków porównania opracowany zostanie model symulacyjny użytkownika, umożliwiający reprezentację różnych profili funkcjonowania oraz ich reakcji na wykonywanie zadań i odpoczynek. Na tej podstawie przeprowadzone zostanie porównanie wybranych modeli planistycznych dostosowanych do poszczególnych profili użytkowników, z wykorzystaniem zdefiniowanych scenariuszy badawczych oraz miar jakości. Eksperyment zostanie zrealizowany na bazie augmentowanych, ogólnodostępnych danych, co pozwoli na uproszczenie przygotowania środowiska badawczego oraz zapewnienie weryfikowalności całego procesu.

Dodatkowym celem pracy jest ocena wyników uzyskanych przez wybrane metody planowania pod kątem ich zdolności do dostosowania się do dynamicznego środowiska, potrzeb konkretnych użytkowników, narzuconych ograniczeń związanych z zadaniami oraz pojawiających się zakłóceń. Ocena zostanie przeprowadzona w oparciu o zdefiniowane miary efektywności, pozwalające na porównanie jakości generowanych harmonogramów oraz stopnia ich dopasowania do przyjętego modelu funkcjonowania użytkownika.

1.3 Układ pracy

Praca została podzielona na [X] rozdziałów. W pierwszym przedstawiono problematykę badawczą oraz cele pracy, a także dokonano przeglądu literatury w zakresie automatyzacji planowania zadań oraz modelowania energii człowieka i rytmu dobowego. Drugi rozdział przedstawia teoretyczne wprowadzenie do rozważanego problemu oraz omówienie wybranych metod. W następnych rozdziałach omówiono kolejno strukturę danych oraz konstrukcję modeli i przeprowadzanego eksperymentu. Ostatecznie w rozdziałach 6 i 7 przedstawiono i omówiono wyniki, przeprowadzając ocenę skuteczności wybranych metod, a także uwzględniono możliwe rozwinięcie tematyki personalizowanego planowania zadań.

2 Przegląd literatury

Niniejszy rozdział przedstawia przegląd literatury stanowiący podstawę do opracowania proponowanego rozwiązania oraz zdefiniowania modelu użytkownika wykorzystywanego w dalszej części pracy. Ze względu na interdyscyplinarny charakter badanego problemu analiza została podzielona na dwa uzupełniające się obszary. Pierwszy z nich obejmuje literaturę z zakresu automatyzacji i personalizacji planowania zadań, ze szczególnym uwzględnieniem metod optymalizacyjnych, uczenia przez wzmacnianie oraz podejść uwzględniających czynniki ludzkie. Część ta została opracowana w formie systematycznego przeglądu literatury, którego celem było uporządkowanie aktualnego stanu badań, identyfikacja dominujących metod oraz wskazanie ograniczeń istniejących rozwiązań.

Druga część rozdziału koncentruje się na zagadnieniach związanych z funkcjonowaniem człowieka, w szczególności rytmem dobowym, chronotypem, zmęczeniem, regeneracją oraz zmiennością wydajności w czasie. Ze względu na pomocniczy charakter tego obszaru względem głównego problemu badawczego zastosowano ukierunkowany przegląd literatury, którego celem jest identyfikacja mechanizmów i zależności istotnych z punktu widzenia budowy modelu symulacyjnego użytkownika, w kontekście systemu harmonogramującego.

Synteza obu obszarów pozwala następnie na sformułowanie założeń projektowanego rozwiązania i przejście do jego formalizacji oraz implementacji.

2.1 Automatyzacja i personalizacja planowania zadań

2.1.1 Metodyka systematycznego przeglądu literatury

Systematyczny przegląd literatury (ang. *Systematic Literature Review*, SLR) to rygorystyczna metoda prowadzenia badań wtórnych, która wykorzystuje zdefiniowaną metodologię do identyfikacji, analizy i interpretacji dostępnych badań istotnych dla konkretnego obszaru badawczego lub zjawiska [Kitchenham, Charters i in., 2007]. W kontekście niniejszej pracy, proces ten pozwolił na obiektywne spojrzenie na problematykę personalizowanego harmonogramowania zadań. Cały proces badawczy składał się z trzech kluczowych faz:

1. **Planowanie przeglądu:** celem tego etapu było sformułowanie pytań badawczych (RQ) oraz zdefiniowanie procedury selekcji. To tutaj określono zakres badań, skupiając się na kwestii optymalizacji algorytmicznej (GA, RL) oraz uwzględnienia w niej psychologii pracy (zmęczenie, prokrastynacja).
2. **Realizacja przeglądu:** głównym zadaniem w tej fazie było opracowanie strategii wyszukiwania dla wybranych baz danych (ACM, IEEE, Science@Direct, Springer Link). Etap ten obejmował pozyskanie 157 pierwotnych studiów, a następnie ich wielostopniową ocenę. W wyniku rygorystycznej selekcji tytułów, abstraktów oraz oceny jakościowej

(*Quality Assessment*), wyłoniono finalny zbiór 22 publikacji, które stanowią podstawę do odpowiedzi na postawione pytania badawcze.

3. **Raportowanie przeglądu:** ostatni etap polegał na syntezie zebranych danych i sformułowaniu wniosków w ujednoliconym formacie. Wynikiem tej fazy jest niniejszy dokument, który systematyzuje wiedzę na temat trendów w *AI-driven scheduling* i wskazuje kierunki dalszego rozwoju systemów wspierających produktywność osobistą.

2.1.2 Pytania badawcze przeglądu

Praca ta stara się przedstawić źródła i obserwowane w nich trendy w temacie personalizowanej automatyzacji zadań. W tym celu praca stara się odpowiedzieć na postawione pytania badawcze (RQ) zaprezentowane w tabeli 2.1.

Tabela 2.1: Pytania badawcze (*Research Questions*) sformułowane na potrzeby przeglądu.

ID	Pytanie badawcze (<i>Research Question</i>)
RQ1	Jakie są obecne podstawy algorytmiczne w personalizowanym planowaniu zadań i jak wybrane metody (GA, RL, agenci AI) wypadają w bezpośrednim porównaniu?
RQ2	Jakie parametry i ograniczenia skoncentrowane na użytkowniku (np. zmęczenie, przerwy, rytm okołodobowy) są najczęściej włączane do omawianych modeli?
RQ3	W jaki sposób dane o historycznej wydajności użytkownika (np. średni czas realizacji zadań) są wykorzystywane do personalizacji przyszłych przewidywań w harmonogramie?
RQ4	Jakie są główne metody weryfikacji, wyzwania oraz ograniczenia zidentyfikowane w aktualnych rozwiązaniach dotyczących planowania zadań?

2.1.3 Strategia wyszukiwania

Strategia wyszukiwania opierała się na serii zapytań przeprowadzonych w czterech cyfrowych bazach danych: ACM Digital Library, IEEE Digital Library, Science@Direct oraz Springer Link. W celu precyzyjnego sformułowania pytań badawczych i określenia zakresu przeglądu, wykorzystano metodę PICOC (*Population, Intervention, Comparison, Outcome, Context*), która pozwoliła na zdefiniowanie następujących ram badania:

- **Populacja (*Population*):** Publikacje naukowe raportujące systemy planowania i harmonogramowania zadań, ze szczególnym uwzględnieniem modeli adaptowalnych dla indywidualnych użytkowników lub małych zespołów.
- **Interwencja (*Intervention*):** Technologie i algorytmy optymalizacyjne, w szczególności algorytmy genetyczne (GA), uczenie przez wzmacnianie (RL) oraz agenci AI wykorzystywani do generowania harmonogramów zadań.

- **Porównanie (*Comparison*):** Pozyskane badania nie są bezpośrednio porównywane z grupą kontrolną, jednak analiza skupia się na porównaniu wydajności różnych podejść AI (np. GA vs. RL) pod kątem ich zdolności adaptacyjnych.
- **Wyniki (*Outcomes*):** Kluczowe parametry obejmują efektywność algorytmów, metryki produktywności, uwzględnienie ograniczeń dotyczących odpoczynku i przerw oraz zdolność systemu do dynamicznego dostosowania się do spersonalizowanego tempa pracy użytkownika.
- **Kontekst (*Context*):** Systemy produktywności osobistej, inżynieria oprogramowania oraz szeroko pojęte środowiska IT, w których efektywne zarządzanie czasem i dobrostan pracownika są kluczowe.

Mając powyższe na uwadze, po przeprowadzeniu iteracyjnych testów, zdefiniowano następujący ciąg wyszukiwania (ang. *search string*) do odpytania wybranych baz danych:

("task scheduling" OR "task planning" OR "time management") AND ("genetic algorithm" OR "reinforcement learning" OR "AI agent" OR "intelligent agent") AND ("personalization" OR "fatigue" OR "rest" OR "human factors")

2.1.4 Warunki uwzględnienia i wykluczenia

W celu filtrowania wyników wyszukiwania uzyskanych z baz danych postawiono warunki uwzględniania (IC) i wykluczenia (EC) prac, zaprezentowane kolejno w tabeli 2.2 i tabeli 2.3.

Tabela 2.2: Warunki uwzględnienia prac w przeglądzie

ID	Warunek
IC1	Pełne badania o przynajmniej 5 stronach.
IC2	Badania odpowiadające na przynajmniej jedno pytanie badawcze.
IC3	Prace podające praktyczne rozwiązania AI lub algorytmiczne.
IC4	Prace opublikowane w latach 2020-2026.

Tabela 2.3: Warunki wykluczenia prac z przeglądu

ID	Warunek
EC1	Duplikaty prac w różnych bazach.
EC2	Szara literatura.
EC3	Prace niepowiązane z tematem planowania zadań.
EC4	Prace z przed 2020 roku.
EC5	Prace w języku innym niż Polski lub Angielski.

2.1.5 Ocena jakości (*Quality Assessment*)

Po wstępnym filtrowaniu 26 wybranych prac poddano rygorystycznej ocenie jakościowej przy użyciu zestawu ośmiu pytań kontrolnych (QA), na które odpowiadano w skali: Tak (1 pkt), Częściowo (0.5 pkt), Nie (0 pkt).

Pytania oceniające obejmowały:

1. Czy badanie w sposób jawny modeluje ograniczenia ludzkie (zmęczenie, przerwy, rytm okołodobowy)?
2. Czy oceniono zdolność algorytmu do adaptacji w dynamicznym środowisku?
3. Czy algorytm harmonogramowania został jasno opisany?
4. Czy praca wnosi wkład w personalizację produktywności?
5. Czy cele i zakres badania są jasno określone?
6. Czy omówiono ograniczenia proponowanego podejścia?
7. Czy wyniki są poparte eksperymentami lub symulacjami?
8. Czy kontekst badania (przemysł vs nauka) został odpowiednio opisany?


Do ostatecznej syntezy danych dopuszczono wyłącznie prace, które uzyskały wynik powyżej 4.5 punktu. W rezultacie finalny zbiór badań podstawowych (ang. *primary studies*) wyniósł 22 artykuły.

2.1.6 Procedura selekcji


Przeszukanie baz danych za pomocą zdefiniowanego ciągu wyszukiwania zaowocowało zbiorem 157 publikacji. Rozkład prac pomiędzy poszczególne źródła prezentował się następująco: 85 (54.1%) prac z bazy ACM Digital Library, 68 (43.3%) z Science@Direct, 3 (1.9%) z IEEE Digital Library oraz 1 (0.6%) ze Springer Link (Rys. 2.1).

Zgromadzone prace zostały przefiltrowane w czterech etapach:

1. **Wyszukiwanie wstępne:** zgromadzenie pełnej puli tekstów na podstawie słów kluczowych (157 prac).
2. **Usuwanie duplikatów:** identyfikacja i usunięcie powtarzających się rekordów pomiędzy bazami (w analizowanym zbiorze nie zidentyfikowano duplikatów ze względu na specyficzne filtry baz).



Rys. 2.1: Rozkład artykułów na poszczególne źródła



Rys. 2.2: Rozkład zaakceptowanych prac w porównaniu z początkowymi wynikami wyszukiwania

3. **Selekcja na podstawie tytułów i abstraktów:** zastosowanie kryteriów włączenia i wyłączenia do metadanych artykułów. Na tym etapie odrzucono prace dotyczące wyłącznie szeregowania procesów systemowych lub chmurowych, pozostawiając 26 publikacji.
4. **Selekcja na podstawie pełnej treści i oceny jakości (QA):** szczegółowa lektura tekstów oraz ocena według 8 pytań kontrolnych (rozdział 2.1.5). Do końcowej analizy zakwalifikowano 22 prace, które przekroczyły próg punktowy 4,5.

Po wstępnym filtrowaniu pozostało odpowiednio: 5 dla ACM, 19 dla Science@Direct, 1 dla IEEE oraz ok. 1 dla bazy Springer (Rysunek 2.2).

Opisany proces, zilustrowany w tabeli 2.4, pozwolił na wyłonienie najbardziej relevantnych badań pierwotnych odpowiadających na postawione pytania badawcze.

Tabela 2.4: Etapy selekcji artykułów i liczba prac zakwalifikowanych.

Etap selekcji	ACM	Science@Direct	IEEE	Springer	Wszystkie
Wyszukiwanie wstępne	85	68	3	1	157
Usuwanie duplikatów	85	68	3	1	157
Analiza tytułów i abstraktów	5	19	1	1	26
Pełna analiza treści (Finalny zbiór)	2	18	1	1	22

2.1.7 Ekstrakcja i synteza danych

Ostatnim etapem fazy realizacji przeglądu było systematyczne pozyskanie danych z 22 zakwalifikowanych studiów pierwotnych. W tym celu opracowano formularz ekstrakcji danych (ang. *Data Extraction Form*), którego strukturę zaprojektowano tak, aby bezpośrednio wspierała odpowiedzi na postawione pytania badawcze (RQ1-RQ4).

Formularz składał się z zestawu pól kategoryzujących aspekty techniczne algorytmów oraz specyficzne parametry uwzględniające czynnik ludzki. Szczegółowy opis pól formularza przedstawia Tabela 2.5.


Tabela 2.5: Struktura formularza ekstrakcji danych.

Pole danych	Typ danych	Uzasadnienie / Powiązanie z RQ
Typ algorytmu	Kategoria	Klasyfikacja metod (GA, RL, Agenci AI, Inne). (RQ1).
Focus na personalizację	Boolean (T/N)	Ocena, czy model realnie adaptuje się do historii użytkownika. (RQ3).
Modelowanie odpoczynku	Kategoria	Rozróżnienie między aktywnym planowaniem przerw a pasywnym stanem bezczynności. (RQ2).
Metoda weryfikacji	Kategoria	Identyfikacja sposobu walidacji (Symulacja, Eksperyment z użytkownikami, Case Study). (RQ4).
Skalowalność	Boolean (T/N)	Ocena, czy rozwiązanie może być stosowane przy dużej liczbie zadań/użytkowników. (RQ4).
Główne wyzwanie	Tekstowe	Opis barier technologicznych lub psychologicznych (np. błąd planowania). (RQ4).

Proces ekstrakcji został przeprowadzony przy użyciu narzędzia Parsifal, co zapewniło spójność danych. W przypadku pól kategorycznych (np. modelowanie odpoczynku), każda praca była analizowana pod kątem tego, czy przerwy w pracy są traktowane jako zaplanowany element regeneracji (*active rest period*), czy jedynie jako brak zadań w systemie (*passive idle*). Dane te posłużyły w dalszej części pracy do przeprowadzenia syntezy ilościowej i jakościowej.

2.1.8 Wyniki systematycznego przeglądu literatury

W tym rozdziale przedstawiono wyniki projektu badawczego przeprowadzonego na wybranych 22 pracach, które przedstawiono w tabeli 2.6. Każda z nich została poddana szczegółowej



Rys. 2.3: Rozkład liczności wybranych prac na przestrzeni lat.

ekstrakcji danych pod kątem postawionych pytań badawczych.

2.1.9 Opis badań podstawowych

Na potrzeby tego badania analizowane były jedynie prace z lat 2020-2026 w celu sprawdzenia aktualnych trendów i nowych rozwiązań dla problemów dynamicznego środowiska i uwzględnienia cech ludzkich w planowaniu. Liczność wybranych prac na przestrzeni lat została zaprezentowana na rysunku 2.3

2.1.10 Wykaz analizy jakości (*Quality Assessment*)

Na podstawie warunków przedstawionych w rozdziale 2.1.5 oceniono wybrane prace w celu ustalenia ich wartości merytorycznej w kontekście tego badania, co zaprezentowano w tabeli 2.7. Średnia jakość prac to około 80%. Na szczególną uwagę zasługują prace Hämmerle i in. [Hämmerle i in., 2025] oraz Gönül i in. [Gönül i in., 2021], które jako jedyne uzyskały maksymalną ocenę w procesie *Quality Assessment*. Prace te stanowią wzorzec metodologiczny, łącząc zaawansowane modele uczenia przez wzmacnianie (RL) z rygorystyczną weryfikacją w warunkach zbliżonych do rzeczywistych, przy jednoczesnym pełnym uwzględnieniu dynamiki ludzkiego zmęczenia.

2.1.11 RQ1: Jakie są obecne podstawy algorytmiczne w personalizowanym planowaniu zadań i jak wybrane metody (GA, RL, agenci AI) wypadają w bezpośrednim porównaniu?


Analiza wykorzystanych technologii (rysunek 2.4) wykazuje znaczną różnorodność w podejściu do problemu harmonogramowania, co świadczy o odejściu od prostych modeli statycznych na rzecz systemów wysoce adaptacyjnych. Choć literatura tradycyjna opiera się głównie na klasycznych algorytmach metaheurystycznych, w badaniach z lat 2020–2026 zauważalny jest wyraźny wzrost zainteresowania metodami dynamicznymi, zdolnymi do reagowania na zmienność ludzkiego działania w czasie rzeczywistym.

Tabela 2.6: Zestawienie wybranych artykułów pierwotnych.

ID	Tytuł artykułu	Wpis
1	Platform-based task assignment for social manufacturing (PBTA4SM): State-of-the-art review and future directions	[Bao i in., 2025]
2	From Conversation to Orchestration: HCI Challenges and Opportunities in Interactive Multi-Agentive Systems	[Schömbbs i in., 2026]
3	Dual task scheduling strategy for personalized multi-objective optimization of cycle time and fatigue in human-robot collaboration	[Chand i Lu, 2023]
4	Task Allocation in Human-Robot Collaboration (HRC) Based on Task Characteristics and Agent Capability for Mold Assembly	[Liau i Ryu, 2020]
5	An approach to task scheduling in an end-of-line quality assurance situation with human-robot cooperation	[Hämmerle i in., 2025]
6	Hierarchical online automated planning for a flexible manufacturing system	[Dong i in., 2024]
7	Towards a science exocortex	[Yager, 2024]
8	JSHM: A dynamic flexible job-shop scheduling method with human-machine collaboration	[An i in., 2026]
9	Tourist trip planning with priority discipline	[Hu i in., 2025]
10	Future-Proof Production Scheduling and Control	[Urgo i in., 2025]
11	Real-time physical fatigue risk assessment for construction workers using a teacher-student training paradigm	[Chen i Gu, 2025]
12	Education 4.0: Artificial Intelligence Assisted Task- and Time Planning System	[Haderer i Ciolacu, 2022]
13	A novel real-world human-robot collaboration scheduling problem: a combination of assembly line balancing and flow shop scheduling	[Ding i in., 2025]
14	Intelligent Time Management Recommendations Using Bayesian Optimization	[Chandramowleeswaran i in., 2024]
15	A reinforcement learning based algorithm for personalization of digital, just-in-time, adaptive interventions	[Gönül i in., 2021]
16	Can large language models independently complete tasks? A dynamic evaluation framework for multi-turn task planning and completion	[Gao i in., 2025]
17	Development of a new personalized staff-scheduling method with a work-life balance perspective: case of a hospital	[Koruca, Emek i Gulmez, 2023]
18	Embracing open innovation in hospitality management: Leveraging AI-driven dynamic scheduling systems for complex resource optimization and enhanced guest satisfaction	[Pitakaso i in., 2025]
19	Bridging the Gap Between Time Management Research and Task Management App Design: A Study on the Integration of Planning Fallacy Mitigation Strategies	[Ahmetoglu, Brumby i Cox, 2024]
20	Task Allocation in Human-Robot Collaboration: A Simulation-based approach to optimize Operator's Productivity and Ergonomics	[Baratta i in., 2024]
21	Digital twin-based framework for an efficient execution of CPPS reconfiguration through human-robot collaboration	[Ciampi i in., 2025]
22	A competence-time-quality scheduling model of multi-skilled staff for IT project portfolio	[Chen i in., 2020]

Tabela 2.7: Zestawienie wybranych artykułów pierwotnych.

ID	QA1	QA2	QA3	QA4	QA5	QA6	QA7	QA8	Razem
1 [Bao i in., 2025]	0	0.5	0.5	0.5	1	1	0.5	1	5
2 [Schömbbs i in., 2026]	0.5	1	0.5	0	1	1	0.5	1	5.5
3 [Chand i Lu, 2023]	1	0.5	1	1	1	0.5	1	1	7
4 [Liau i Ryu, 2020]	1	1	1	1	1	0.5	1	1	7.5
5 [Hämmerle i in., 2025]	1	1	1	1	1	1	1	1	8
6 [Dong i in., 2024]	0	1	1	0	1	0.5	1	1	5.5
7 [Yager, 2024]	1	1	0.5	1	1	1	0.5	1	7
8 [An i in., 2026]	1	1	1	1	1	0.5	1	1	7.5
9 [Hu i in., 2025]	0.5	0.5	1	1	1	1	1	1	7
10 [Urgo i in., 2025]	0	1	1	0	1	0.5	1	1	5.5
11 [Chen i Gu, 2025]	1	1	1	1	1	0.5	1	1	7.5
12 [Haderer i Cio-lacu, 2022]	1	0.5	1	1	1	0.5	1	1	7
13 [Ding i in., 2025]	0	0.5	1	0	1	0.5	1	1	5
14 [Chandramow-leeswaran i in., 2024]	0.5	1	1	1	1	0.5	1	1	7
15 [Gönül i in., 2021]	1	1	1	1	1	1	1	1	8
16 [Gao i in., 2025]	0	1	1	1	1	1	1	0.5	6.5
17 [Koruca, Emek i Gulmez, 2023]	1	0.5	1	1	1	0.5	1	1	7
18 [Pitakaso i in., 2025]	0.5	1	0.5	0.5	1	0.5	0.5	1	5.5
19 [Ahmetoglu, Brumby i Cox, 2024]	1	0	0	1	1	0.5	0.5	1	5
20 [Baratta i in., 2024]	1	0.5	1	1	1	0.5	1	1	7
21 [Ciampi i in., 2025]	0.5	1	1	0.5	1	0.5	1	1	6.5
22 [Chen i in., 2020]	0.5	0.5	1	0.5	1	0.5	1	1	6



Rys. 2.4: Rozkład typów algorytmów w analizowanych badaniach.

Jednym z kluczowych filarów technologicznych, zidentyfikowanym w 18,2% analizowanych prac, jest uczenie przez wzmacnianie (*Reinforcement Learning* - RL). Metoda ta znajduje zastosowanie przede wszystkim w scenariuszach, w których system musi uczyć się preferencji użytkownika na bieżąco i wdrażać interwencje typu *Just-in-Time* [Gönül i in., 2021]. Zaawansowane implementacje, takie jak model JSHM, łączą głębokie RL z wielozadaniowymi grafowymi sieciami neuronowymi (MBGCN), co pozwala na precyzyjne i jednocześnie modelowanie umiejętności operatora, stopnia trudności zadań oraz indywidualnych tendencji behawioralnych [An i in., 2026].

Równorzędne znaczenie pod względem częstotliwości występowania (18,2% przypadków) zachowują algorytmy genetyczne (GA). W najnowszych badaniach rzadko występują one w swojej podstawowej formie; najczęściej są modyfikowane w celu zwiększenia ich wydajności w środowiskach dynamicznych. Ich rola koncentruje się głównie na optymalizacji wielokryterialnej, mającej na celu znalezienie stabilnego balansu między wydajnością systemu a poziomem zmęczenia człowieka [Chand i Lu, 2023]. Często spotyka się tu również hybrydy, łączące GA z algorytmami przeszukiwania lokalnego (np. *Tabu Search*), co pozwala na skuteczne rozwiązywanie problemów synchronizacji w złożonych procesach współpracy [Ding i in., 2025].

Kolejną istotną grupę, stanowiącą 13,6% zbioru, tworzą Agenci AI. Badania w tym obszarze koncentrują się na proaktywnej komunikacji i orkiestracji działań w interaktywnych środowiskach wieloagentowych [Schömbbs i in., 2026]. Agenci ci pełnią rolę kognitywnego rozszerzenia

użytkownika – przykładem jest koncepcja „egzokorteksu naukowego”, w której rój agentów wspiera badacza w podejmowaniu decyzji i planowaniu długich łańcuchów zadań [Yager, 2024].

Najlichniesza kategoria, obejmująca aż 41% badanych rozwiązań (grupa „Inne i Hybrydy”), odzwierciedla dużą innowacyjność obecnych badań. W tej grupie dominują nowatorskie zastosowania dużych modeli językowych (LLM), które są oceniane pod kątem ich zdolności do samodzielnego planowania i wykonywania zadań w scenariuszach wieloetapowych [Gao i in., 2025]. Ponadto analiza wskazuje na istotny wkład optymalizacji bayesowskiej w generowanie rekomendacji czasowych przy ograniczonych danych [Chandramowleeswaran i in., 2024] oraz wykorzystanie architektur cyfrowych bliźniaków (*Digital Twins*) opartych na sieciach neuronowych informowanych fizycznie (PINNs) do precyzyjnego przewidywania stanów systemu [Ciampi i in., 2025]. Tak szerokie spektrum metod potwierdza, że skuteczne, personalizowane planowanie wymaga łączenia zaawansowanej analityki danych z elastycznymi modelami decyzyjnymi.

2.1.12 RQ2: Jakie parametry i ograniczenia skoncentrowane na użytkowniku (np. zmęczenie, przerwy, rytm okołodobowy) są najczęściej włączane do omawianych modeli?

Modelowanie ograniczeń ludzkich w analizowanej literaturze wykracza znacząco poza proste ramy czasowe, kładąc nacisk na procesy biologiczne, ergonomiczne i psychofizyczne. Kluczowym parametrem uwzględnianym w badaniach jest zmęczenie fizyczne oraz kognitywne, przy czym wyniki przeglądu wskazują na istotną i trwającą zmianę paradygmatu w podejściu do regeneracji sił użytkownika.

Obecnie **32%** analizowanych prac implementuje koncepcję aktywnych przerw (*active rest period*), w której odpoczynek nie jest traktowany jako zwykły przestój, lecz jako jawne zadanie regeneracyjne mające na celu czynne obniżenie poziomu zmęczenia (*fatigue mitigation*). Podejście to jest szczególnie widoczne w pracach dotyczących współpracy człowiek-robot, gdzie optymalizacja czasu cyklu jest bezpośrednio powiązana z modelem wypoczynku operatora [Chand i Lu, 2023; Hämmerle i in., 2025], a także w systemach monitorujących ryzyko fizyczne w czasie rzeczywistym [Chen i Gu, 2025; Baratta i in., 2024]. Ponadto, aktywne planowanie interwencji w odpowiednich momentach spoczynku jest kluczowe dla skuteczności personalizowanych systemów zdrowotnych [Gönül i in., 2021].

Mimo tego nowoczesnego trendu, **27%** publikacji wciąż stosuje podejście pasywne (*passive idle*), gdzie odpoczynek jest jedynie efektem braku dostępnych zadań w systemie, co często wynika ze specyfiki alokacji zadań opartej głównie na charakterystyce maszyn, a nie człowieka [Liau i Ryu, 2020; Dong i in., 2024].

Warto zauważyć, że w **41%** przypadków model odpoczynku nie został jawnie zdefiniowany, co wskazuje na potrzebę dalszych badań nad standaryzacją okresów regeneracji. Poza samym zmęczeniem, zaawansowane modele integrują parametry takie jak zasady *work-life balance*

[Koruca, Emek i Gulmez, 2023], ergonomia postawy [Baratta i in., 2024] oraz indywidualna wydajność kognitywna, co pozwala na ochronę zdrowia przy zachowaniu efektywności.

2.1.13 RQ3: W jaki sposób dane o historycznej wydajności użytkownika (np. średni czas realizacji zadań) są wykorzystywane do personalizacji przyszłych przewidywań w harmonogramie?


Dane historyczne stanowią fundament adaptacyjności systemów personalizowanych, umożliwiając ciągłe dostrajanie parametrów algorytmicznych do specyfiki konkretnego użytkownika. Jak wykazano w procesie ekstrakcji danych, aż **68%** analizowanych prac (15 artykułów) wykazuje wyraźną koncentrację na zagadnieniu personalizacji (*Personalization Focus*), co potwierdza trend odchodzenia od sztywnych systemów planistycznych na rzecz rozwiązań adaptacyjnych [An i in., 2026; Chandramowleeswaran i in., 2024].

Historia wydajności jest wykorzystywana przede wszystkim do modelowania indywidualnych krzywych uczenia się i zapominania, co pozwala systemowi przewidzieć tempo nabywania wprawy i skracać szacowany czas trwania kolejnych zadań [Chen i in., 2020]. Dodatkowo, analiza historycznych różnic między założonym planem a rzeczywistym wykonaniem służy do łagodzenia skutków błędu planowania (*planning fallacy*) poprzez automatyczną korektę przyszłych estymacji czasu [Ahmetoglu, Brumby i Cox, 2024]. Dzięki wysokiemu poziomowi personalizacji, algorytmy uczą się rzeczywistego tempa pracy użytkownika, co pozwala na unikanie przeciążenia informacyjnego i kognitywnego [Schömbis i in., 2026; Gönül i in., 2021]. Systemy te potrafią również przewidywać momenty skłonności do prokrastynacji, sugerując podział przytłaczających obowiązków na mniejsze etapy w oparciu o wcześniejsze sukcesy użytkownika w realizacji planu [Haderer i Ciolacu, 2022].

2.1.14 RQ4: Jakie są główne metody weryfikacji, wyzwania oraz ograniczenia zidentyfikowane w aktualnych rozwiązaniach dotyczących planowania zadań?

Weryfikacja proponowanych rozwiązań w obszarze personalizowanego harmonogramowania opiera się na różnorodnych metodach badawczych, co zilustrowano na rysunku 2.5. Wyniki przeglądu wskazują na wyraźną dominację symulacji, które zostały wykorzystane w 50% analizowanych prac. Trend ten wynika przede wszystkim z łatwości generowania dużych i zróżnicowanych zbiorów danych testowych, co jest niezbędne do oceny wydajności złożonych algorytmów. Niepokojącym zjawiskiem pozostaje jednak relatywnie mała liczba eksperymentów z udziałem realnych użytkowników (*User Experiments*), które stanowią jedynie 13,6% zbioru. Taka dysproporcja sugeruje, że wiele współczesnych modeli zachowuje charakter teoretyczny i może napotykać trudności w bezpośrednim starciu z nieprzewidywalnymi zachowaniami ludzkimi w rzeczywistym środowisku pracy.

Pewną próbę wypełnienia luki między teorią a praktyką stanowią podejścia wykorzystujące



Rys. 2.5: Metody weryfikacji stosowane w analizowanych badaniach.

technologie rzeczywistości mieszanej (MR) oraz cyfrowe bliźniaki. Przykładowo, integracja modułów MR z architekturą bliźniaka cyfrowego pozwala na bezpieczne testowanie interakcji człowiek-robot przy jednoczesnym zachowaniu wysokiej wierności odwzorowania warunków fizycznych [Ciampi i in., 2025]. W nielicznych eksperymentach z użytkownikami badacze koncentrują się nie tylko na twardych metrykach wydajności, ale również na subiektywnej satysfakcji, poziomie stresu oraz wskaźniku skutecznego ukończenia zadań [Haderer i Ciolacu, 2022; Chandramowleeswaran i in., 2024].

Analiza literatury pozwoliła na zidentyfikowanie szeregu barier technologicznych i psychologicznych, które ograniczają skuteczność obecnych systemów. Jednym z najpoważniejszych wyzwań jest problem wyjaśnialności (*explainability*) decyzji podejmowanych przez sztuczną inteligencję. Jak wskazują autorzy koncepcji asystentów kognitywnych, brak przejrzystego uzasadnienia, dlaczego system sugeruje zmianę planu lub konieczność odpoczynku, znacząco obniża zaufanie użytkownika i rygor przestrzegania wygenerowanego harmonogramu [Yager, 2024]. Wyzwaniem technicznym pozostaje również wykładniczy wzrost złożoności obliczeniowej w przypadku dużej liczby zadań [Dong i in., 2024] oraz tendencja nowoczesnych modeli językowych (LLM) do gubienia kontekstu podczas planowania długofalowych procesów [Gao i in., 2025].

Najważniejszym ograniczeniem o charakterze ludzkim pozostaje jednak błąd planowania (*planning fallacy*) oraz związana z nim niska rzetelność danych wejściowych. Użytkownicy wykazują systematyczną tendencję do niedoszacowania czasu potrzebnego na realizację zadań, co prowadzi do dezaktualizacji harmonogramu już w początkowej fazie jego wykonywania [Ahmetoglu, Brumby i Cox, 2024]. Problem ten potęguje trudność w precyzyjnym i obiektywnym określaniu momentów zmęczenia ze względu na duże różnice międzysobnicze [Chen i Gu, 2025]. W efekcie, kluczowym wyzwaniem dla przyszłych systemów pozostaje zapewnienie

wysokiej odporności (*robustness*) na zakłócenia oraz zdolność do ciągłej, dynamicznej rekonfiguracji planu bez powodowania nadmiernego obciążenia informacyjnego u użytkownika [Urgo i in., 2025; Schömbs i in., 2026].

Tabela 2.8: Szczegółowe zestawienie wyzwań badawczych dla każdej pracy; część 1

ID	Artykuł	Główne wyzwanie
1	Platform-based task assignment for social manufacturing (PBTA4SM): State-of-the-art review and future directions	Zapewnienie zaufania i bezpieczeństwa zdecentralizowanej sieci.
2	From Conversation to Orchestration: HCI Challenges and Opportunities in Interactive Multi-Agentive Systems	Przeciążenie użytkownika zarządzaniem wieloma agentami.
3	Dual task scheduling strategy for personalized multi-objective optimization of cycle time and fatigue in human-robot collaboration	Znalezienie optymalnego balansu między cyklem pracy a zmęczeniem człowieka.
4	Task Allocation in Human-Robot Collaboration (HRC) Based on Task Characteristics and Agent Capability for Mold Assembly	Przypisywanie stopnia skomplikowania do możliwości użytkownika.
5	An approach to task scheduling in an end-of-line quality assurance situation with human-robot cooperation	Balancing user fatigue and production speed requirement.
6	Hierarchical online automated planning for a flexible manufacturing system	Wykładnicze zwiększenie złożoności obliczeniowej wraz ze wzrostem liczby zadań.
7	Towards a science exocortex	Uzasadnienie decyzji modelu.
8	JSHM: A dynamic flexible job-shop scheduling method with human-machine collaboration	Dynamiczne dostosowywanie planu do gwałtownego spadku wydajności użytkownika przez zmęczenie.
9	Tourist trip planning with priority discipline	Uwzględnianie w czasie i niepomijanie niskopriorytetowych zadań.
10	Future-Proof Production Scheduling and Control	Zapewnienie jak największej stabilności planu przy nagłych zmianach sytuacji.
11	Real-time physical fatigue risk assessment for construction workers using a teacher-student training paradigm	Rozpoznawanie zmęczenia w złych warunkach.

2.1.15 Dyskusja

Jak wynika z analizy zgromadzonych prac, współczesne badania nad harmonogramowaniem zadań koncentrują się na odejściu od sztywnych modeli matematycznych na rzecz systemów wysoce adaptacyjnych. Główną zaletą zidentyfikowanych rozwiązań jest ich zdolność do dynamicznego reagowania na zmienność ludzkiego działania, co jest realizowane głównie poprzez wykorzystanie uczenia przez wzmacnianie (RL) oraz algorytmów genetycznych (GA), które

Tabela 2.9: Szczegółowe zestawienie wyzwań badawczych dla każdej pracy; część 2

ID	Artykuł	Główne wyzwanie
12	Education 4.0: Artificial Intelligence Assisted Task- and Time Planning System	Znalezienie odpowiednich podziałów na podzadania w celu minimalizacji prokrastynacji.
13	A novel real-world human-robot collaboration scheduling problem: a combination of assembly line balancing and flow shop scheduling	Synchronizacja możliwości użytkownika z wydajnością maszyny.
14	Intelligent Time Management Recommendations Using Bayesian Optimization	Małe prawdopodobieństwo rzetelnego udziału użytkownika w dostarczaniu faktycznych informacji o czasie wykonania zadań.
15	A reinforcement learning based algorithm for personalization of digital, just-in-time, adaptive interventions	Unikanie nadmiernego powiadamiania w okresach odpoczynku.
16	Can large language models independently complete tasks? A dynamic evaluation framework for multi-turn task planning and completion	Gubienie kontekstu przez agenta AI w wieloetapowym procesie.
17	Development of a new personalized staff-scheduling method with a work-life balance perspective: case of a hospital	Znalezienie równowagi między wieloma preferencjami użytkownika.
18	Embracing open innovation in hospitality management: Leveraging AI-driven dynamic scheduling systems for complex resource optimization and enhanced guest satisfaction	Dostosowanie do nagłych zmian w zapotrzebowaniu.
19	Bridging the Gap Between Time Management Research and Task Management App Design: A Study on the Integration of Planning Fallacy Mitigation Strategies	Skłonność użytkowników do niedoszacowania wymaganego czasu na zadanie.
20	Task Allocation in Human-Robot Collaboration: A Simulation-based approach to optimize Operator's Productivity and Ergonomics	Zapewnienie wysokiej wydajności bez przekraczania możliwości użytkownika.
21	Digital twin-based framework for an efficient execution of CPPS reconfiguration through human-robot collaboration	Uwzględnienie opóźnień w przesłaniu danych.
22	A competence-time-quality scheduling model of multi-skilled staff for IT project portfolio	Uwzględnienie dodatkowego czasu na ponowne przystosowanie do żądco wykonywanych zadań.

stanowią dwa równorzędne filary technologiczne (po 18,2% udziału). O ile algorytmy genetyczne sprawdzają się w optymalizacji wielokryterialnej, dążąc do równowagi między czasem cyklu a zmęczeniem operatora [Chand i Lu, 2023], o tyle metody RL pozwalają na naukę preferencji użytkownika w czasie rzeczywistym i wdrażanie interwencji typu *just-in-time* [Gönül i in., 2021]. Należy jednak zauważyć, że same algorytmy nie rozwiązują wszystkich problemów personalizacji; kluczowa okazuje się warstwa interakcji człowiek-komputer, realizowana przez agentów AI i duże modele językowe (LLM). Takie systemy, jak model JSHM łączący grafowe sieci neuronowe z RL [An i in., 2026], pozwalają na jednoczesne modelowanie kompetencji i preferencji, co czyni je bardziej kompletnymi niż klasyczne podejścia metaheurystyczne.

Istotnym elementem dyskusji jest zmiana paradygmatu w modelowaniu odpoczynku i zmęczenia. Tradycyjnie czas wolny od zadań traktowano jako pasywny stan bezczynności (*passive idle*), co wciąż jest obecne w 27% badanych prac [Liau i Ryu, 2020]. Jednakże coraz więcej badaczy (32%) słusznie uznaje, że przerwa musi być traktowana jako aktywne zadanie regeneracyjne (*active rest period*), mające na celu zapobieganie spadkom wydajności [Chen i Gu, 2025]. Wprowadzenie tego ograniczenia do modelu matematycznego pozwala na lepszą ochronę zdrowia pracownika przy jednoczesnym zachowaniu ciągłości produkcji. Niemniej jednak, wciąż w 41% publikacji model odpoczynku nie jest jawnie zdefiniowany, co może prowadzić do generowania harmonogramów nierealistycznych w dłuższej perspektywie czasowej. Rozwiązaniem tego problemu wydaje się wykorzystanie danych historycznych o wydajności użytkownika. Jak wykazano, 68% prac stawia personalizację w centrum swojego modelu, wykorzystując krzywe uczenia się do przewidywania tempa pracy [Chen i in., 2020] oraz historyczne opóźnienia do mitygacji błędu planowania (*planning fallacy*), co pozwala na automatyczną korektę przyszłych estymacji czasu [Ahmetoglu, Brumby i Cox, 2024].

Z przeprowadzonej analizy jasno wynika, że metody weryfikacji stosowane w dziedzinie personalizowanego planowania są wciąż niewystarczające. Po pierwsze, dominują symulacje komputerowe (50%), które choć pozwalają na testowanie złożonych scenariuszy [Hämmerle i in., 2025], nie oddają w pełni irracjonalnych zachowań ludzkich, takich jak prokrastynacja mimo zaleceń systemu. Po drugie, relatywnie mała liczba eksperymentów z udziałem realnych użytkowników (13,6%) sprawia, że trudno ocenić rzeczywistą użyteczność tych systemów w praktyce biurowej czy przemysłowej. Ponadto istotną barierą jest problem wyjaśnialności (*explainability*) decyzji podejmowanych przez AI. Jeśli użytkownik nie rozumie, dlaczego system sugeruje zmianę planu lub przerwę, jego zaufanie do narzędzia maleje, co obniża rygor przestrzegania harmonogramu [Yager, 2024], a co za tym idzie, spada użyteczność narzędzia. Konieczne jest zatem przesunięcie uwagi badaczy w stronę bardziej rygorystycznych testów w warunkach rzeczywistych oraz ujednolicenie standardów zbierania danych o zmęczeniu.

2.2 Rytm dobowy i modelowanie funkcjonowania człowieka

2.3 Synteza literatury i luka badawcza

3 Wybrane zagadnienia teoretyczne z zakresu automatyzacji planowania zadań i personalizacji

3.1 Problem automatycznego planowania zadań

3.1.1 Planowanie i harmonogramowanie zadań

3.1.2 Problemy Job-Shop Scheduling i Flexible Job-Shop Scheduling

3.1.3 Modelowanie zadań, zasobów i ograniczeń

3.1.4 Dynamiczne przeplanowanie zadań

3.1.5 Personalizacja i podejście Human-in-the-Loop

3.2 Optymalizacja wielokryterialna

3.2.1 Problem optymalizacji wielokryterialnej

3.2.2 Dominacja Pareto i front Pareto

3.2.3 Algorytmy ewolucyjne w optymalizacji wielokryterialnej

3.2.4 Algorytm NSGA-II

3.2.5 Algorytm NSGA-III

3.3 Uczenie przez wzmacnianie

3.3.1 Podstawy uczenia przez wzmacnianie

3.3.2 Proces decyzyjny Markowa

3.3.3 Funkcja nagrody i polityka agenta

3.3.4 Proximal Policy Optimization

3.3.5 Informacja zwrotna użytkownika w procesie uczenia

3.4 Modelowanie zmienności funkcjonowania człowieka

3.4.1 Rytm okołodobowy

3.4.2 Chronotyp i różnice indywidualne

3.4.3 Zmęczenie i wydajność podczas wykonywania zadań

3.4.4 Odpoczynek i regeneracja

3.4.5 Reprezentacja stanu użytkownika w systemie planowania

4 Wykorzystane dane i stos technologiczny

4.1 Bazy danych

Krótki opis wybranych baz danych i dlaczego, jakie informacje z nich są potrzebne w pracy

Cognitive Performance & Biometric Optimization DS [Üstün, 2026]

Workflow Operations Performance Dataset [Shahzad, 2026]

Human Resource Allocation Dataset [Zara, 2026]

4.2 Augmentacja i synteza danych

W jaki sposób wybrane bazy danych zostały połączone w spójną strukturę, jak zostało rozszerzone i jak generowano dodatkowe dane do eksperymentu

4.3 Wykorzystane technologie

stos technologiczny:

- python,
- pytorch, spinup (<https://spinningup.openai.com/en/latest/algorithms/ppo.html>),
- pymoo (<https://pymoo.org/algorithms/moo/nsga3.html>)

może zostać rozszerzone

5 Konstrukcja eksperymentu porównania metod planowania

Oba wybrane algorytmy poza porównaniem między sobą będą porównywane do ustalonej wersji bazowej, którą będzie plan zadań uporządkowanych po priorytecie i terminie wykonania. (5.4.1)

Oba modele są przetrenowane na próbie różnych użytkowników żeby nauczyć się podstawowych zasad: wyższy priorytet wcześniej, nie przekraczać terminów - tak żeby zmniejszyć losowość na początku działania algorytmu ale nie uczyć jeszcze konkretnych profili.

Dla każdego algorytmu plany są tworzone dla każdego użytkownika osobno i zapisywane do bazy. Plany tworzone są na tydzień i aktualizowane 2 razy dziennie (NSGA) lub po każdym zadaniu (PPO) na koniec każdego dnia zbierane są miary. Ponowne uruchomienia w dzień są aby dostosować się do faktycznie wykonanych do tego momentu zadań i dostosować stan/o-czekiwania na resztę dnia. Eksperyment przeprowadzany jest przez kilka tygodni roboczych żeby zweryfikować czy miary poprawiają się w czasie (personalizacja).

5.1 Składowe elementy uwzględnione w eksperymencie

5.2 Miary oceny

Proponowane miary:

- efektywność harmonogramu - procent zakończonych zadań z wyznaczonych na dzień
- uwzględnienie priorytetu - kary za przekroczenie terminu wykonania zadań z wyższym priorytetem, proporcjonalnie
- uwzględnienie poziomów energetycznych w ciągu dnia - czy zadania bardziej złożone, wymagające są w czasie wyższych poziomów energii i na odwrót
- responsywność na zmiany - wpływ wprowadzenia zakłóceń na plan - czy zmienia się tylko najbliższe otoczenie i nie ma wielkiego wpływu na dalsze zadania - im mniej zmian tym lepiej

5.3 Modelowanie funkcjonowania człowieka

Symulowany będzie ciąg wykonania zadań na podstawie profilu danego użytkownika. Na podstawie ustalonego chronotypu użytkownik ma inną wydajność o różnych godzinach, a także inny poziom umiejętności z różnych rodzajów zadań. To wszystko wpływa na to ile czasu zadanie będzie wykonywane i ile energii użytkownika będzie zużywało.

"Wykonanie" każdego zadania będzie polegało na obliczeniu "rzeczywistego" czasu wykonania zadania i zużycia energii na podstawie wybranych warunków i podstawowych informacji o zadaniu. Wpływa na to wiele czynników jak m.in. dzień tygodnia, aktualny poziom energii, pora dnia, poziom umiejętności w danym typie zadania i same parametry zadania (średnie szacowane wartości czasu/energii).

Modele dostają jedynie informację zwrotną o czasie zakończenia zadania, na podstawie czego mają wydedukować profil użytkownika, jako że poziom energii wpływa na wydajność pracy.

Dodatkowo w symulacji brane pod uwagę będą "przełączenia" między rodzajami zadań, jako że badania pokazują obniżenie produktywności przy częstych zmianach wykonywanych zadań, co wymaga doliczenia czasu na ich zakończenie.

Symulacja musi pozostać w wersji mocno uproszczonej względem realiów, ponieważ w rozważanym problemie faktycznie istnieje za dużo możliwych czynników do przeanalizowania.

Drugi etap będzie działał na ostatniej wersji modelu dla użytkownika i wprowadzał "zakłócenia" do weryfikacji stabilności planu - co się dzieje jak pojawia się takie zadanie z krótkim terminem przed końcem tych co już mamy?

5.4 Architektura modeli

5.4.1 Punkt odniesienia

5.4.2 Niezdominowany Algorytm Sortowania Genetycznego - NSGAPlanner

5.4.3 Proximal Policy Optimization - PPOPlanner

5.5 Plan eksperymentu

Tymczasowa prezentacja zamysłu pracy:

6 Wyniki

6.1 Etap 1

6.2 Etap 2

7 Podsumowanie

7.1 Analiza wyników eksperymentu

7.2 Ocena użyteczności wybranych metod automatyzacji planowania zadań

7.3 Możliwość dalszego rozwoju tematyki pracy

Spis rysunków

2.1	Rozkład artykułów na poszczególne źródła	8
2.2	Rozkład zaakceptowanych prac w porównaniu z początkowymi wynikami wyszukiwania	8
2.3	Rozkład liczności wybranych prac na przestrzeni lat.	10
2.4	Rozkład typów algorytmów w analizowanych badaniach.	13
2.5	Metody weryfikacji stosowane w analizowanych badaniach.	16

Spis tabel

2.1	Pytania badawcze (<i>Research Questions</i>) sformułowane na potrzeby przeglądu. .	5
2.2	Warunki uwzględnienia prac w przeglądzie	6
2.3	Warunki wykluczenia prac z przeglądu	6
2.4	Etapy selekcji artykułów i liczba prac zakwalifikowanych.	9
2.5	Struktura formularza ekstrakcji danych.	9
2.6	Zestawienie wybranych artykułów pierwotnych.	11
2.7	Zestawienie wybranych artykułów pierwotnych.	12
2.8	Szczegółowe zestawienie wyzwań badawczych dla każdej pracy; część 1	17
2.9	Szczegółowe zestawienie wyzwań badawczych dla każdej pracy; część 2	18

Spis kodów